

Question-Guided Directional Prompting for Parameter-Efficient Domain Adaptation of Frozen Multimodal Large Language Models

1 引言

多模态大语言模型已经能够接收图像与文本输入，并以生成方式完成开放式问答 [1, 2, 11]。LLaVA 和 MiniGPT-4 进一步表明，视觉指令调优可以把预训练视觉模块与大语言模型用于多轮图文交互 [?]。但将通用模型用于专业领域时，通常仍需针对新的图像分布和任务语言进行适配。医学视觉问答与电力设备巡检中的现有工作都反映了这类需求 [5, 14, 20]。以设备图像为例，问题可能分别询问部件类别、连接关系或异常位置；即使图像相同，模型需要读取的证据也会随问题变化。完整微调需要更新并保存整套模型参数，多领域部署时还要为各领域维护独立权重，因此训练和存储成本都较高 [6, 7]。

参数高效微调只更新一小部分新增参数。LoRA 用低秩矩阵表示权重增量 [7]，IA³ 通过缩放中间激活完成适配，AdaLoRA 则在训练中分配低秩更新的参数预算 [?]。Prefix Tuning 和 Prompt Tuning 保持骨干权重冻结，优化连续的前缀或输入 Token [10, 12]；P-Tuning v2 将连续 Prompt 扩展到更深的网络层 [?]，类似思路也被用于视觉模型 [9]。Prompt 方法的适配参数容易按领域单独保存，但传统 Soft Prompt 通常对所有样本使用同一组 Token。它能学习训练集共享的任务信息，却不会根据当前问题重新选择图像证据。视觉问答恰好需要这种选择：同一张图像对应不同问题时，相关区域和属性也会改变 [3]。

条件 Prompt 为每个样本生成不同的上下文。在 CLIP[?] 基础上，CoOp 学习任务共享的连续上下文 [?]，CoCoOp 进一步根据图像特征产生实例条件 Token [22]；MaPLe 则在视觉和语言分支中联合学习 Prompt [?]。DRAPE 结合当前指令与视觉特征生成动态 Soft Prompt [8]。另一条相关路线以少量潜在表示汇聚高维输入 [?]：BLIP-2 的 Q-Former 从冻结图像编码器中提取固定长度的视觉表示，InstructBLIP 进一步让指令参与这一过程 [3, 11]。这些工作给出了可用的技术部件，但对于冻结生成式多模态大模型的领域适配，仍需确定从哪一层读取视觉证据、静态 Prompt 和动态 Prompt 如何分工，以及动态表示最终应放在模型的哪个位置。

本文研究 Question-Guided Directional Prompt Tuning (QDPT)，一种面向冻结多模态大语言模型的样本条件 Prompt 适配方法。QDPT 使用当前问题生成一组查询，以视觉编码器中间层的图像 Token 作为键和值，通过定向跨模态注意力提取与问题相关的证据，再将所得表示映射为语言模型侧的动态 Prompt。模型同时保留静态 Prompt，用于学习领域级的共享校准。两类 Prompt 承担不同作用：静态部分描述跨样本重复出现的领域信息，动态部分则根据当前图像和问题改变。训

练过程中，视觉编码器、视觉投影模块和语言模型的原有权重均保持冻结。

QDPT 采用非对称的信息路径。问题负责描述需要寻找什么，图像提供候选证据，匹配后的表示只写入语言模型入口。动态条件分支不会把生成的表示反复写回视觉编码器。这里的出发点并不是假设视觉信息不重要，而是考察冻结视觉特征已经保留可用证据时，适配器能否通过问题引导的检索改善后续回答。跨模态适配宽度 D 进一步提供了一个明确的容量控制量，使同一结构可以在参数开销和任务性能之间调整。

我们在 PathVQA[5] 和 SLAKE[14] 上检验 QDPT，并在统一骨干和评价脚本下与静态 Prompt、CoCoOp-style Prompt 及 LoRA[7, 22] 比较。PathVQA 上，最终 D768 Sandwich 配置的三随机种子平均结果与 Full-Attention LoRA-r8 接近；SLAKE 上，LoRA 仍高出 4.87 个百分点。自建电力电气数据集提供了另一类专业图像上的补充验证，QDPT 在固定留出集上取得最高点估计，但该实验目前只有一个随机种子。现有实现中，QDPT 在 PathVQA 和 SLAKE 上的训练速度分别约为 LoRA-r8 的 2.24 倍和 1.49 倍。这些数值只描述本文的软硬件环境与实现。

实验还表明，Prompt 在因果 LLM 中的位置不能任意互换。固定参数量与训练设置后， $[P^t; M(I); P^d; T(X)]$ 的 Sandwich 顺序优于两种位置对照。将 D768 密集输出头压缩至秩 256 虽然减少 21.84% 的可训练参数，却使 Overall 下降 3.36 个百分点。多随机种子结果给出了另一项限制：QDPT 在 PathVQA 上的波动高于静态 Prompt 和 LoRA。因此，本文将 QDPT 定位为冻结 MLLM 的一种可选适配路径，并同时报告它的准确率、训练耗时和稳定性边界。

本文的主要贡献如下：

- 提出 QDPT，在不更新多模态大模型骨干权重的条件下，用当前问题定向读取图像证据并生成样本相关的语言 Prompt。
- 将样本共享的领域校准与问题条件的视觉证据提取分开，并为冻结的因果 LLM 设计静态 Prompt、视觉 Token 与动态 Prompt 的 Sandwich 排列。
- 通过 Prompt 位置和输出头压缩实验分析结构选择，并用多随机种子结果报告动态 Prompt 的运行波动。
- 在两个公开 VQA 数据集和一个电力电气数据集上比较 QDPT、静态 Prompt、CoCoOp-style Prompt 与 LoRA，报告其准确率、训练耗时和适用边界。

2 相关工作

2.1 多模态大模型的参数高效适配

参数高效微调通过限制可训练参数的范围，降低大模型适配和多任务部署的成本。Adapter 在 Transformer 层之间加入小型可训练模块 [6]，LoRA 用低秩矩阵表示权重增量 [7]。IA³ 学习作用于激活的缩放向量 [?]，AdaLoRA 则根据训练中的重要性分配低秩预算 [?]。这些方法都保留预训练权重，但修改中间变换的方式不同。针对多模态大模型的实证研究表明，不同 PEFT 方法的效果与可训练模块所在位置密切相关，单看参数量不足以判断实际训练成本或任务性能 [23]。

连续 Prompt 直接优化输入或中间表示。Prefix Tuning 在 Transformer 各层引入可训练前缀 [12], Prompt Tuning 优化输入侧的连续 Token [10], P-Tuning v2 则把连续 Prompt 用于更深的网络层 [?]。Visual Prompt Tuning [9] 和 VL-Adapter [18] 将参数高效适配扩展到视觉及视觉语言任务, MaPLe 进一步在视觉和语言分支之间耦合 Prompt [?]。Prompt 参数可以按领域单独保存, 也不要求更新骨干权重。不过, 多数静态 Prompt 对所有样本保持不变, 适合记录任务或领域中的共享信息, 却无法直接表达当前问题与图像之间的对应关系。QDPT 保留静态 Prompt, 同时加入由当前样本生成的动态 Prompt。

2.2 条件 Prompt 与问题引导的视觉聚合

条件 Prompt 根据输入为每个样本生成不同的上下文。CLIP 通过自然语言监督建立图文共享表示 [?], CoOp 在此基础上学习任务共享的连续上下文 [?]。CoCoOp 进一步使用图像特征生成实例条件 Token, 以减轻固定 Prompt 对训练类别的过拟合 [22], 其输出仍服务于图像分类的文本表示。生成式视觉问答中的条件关系不同: 问题限定检索目标, 图像提供回答所需的证据。QDPT 因此使用问题生成 Query, 而不是只用图像生成上下文。

Perceiver 使用少量潜在向量通过 Cross-Attention 读取高维输入 [?], TokenLearner 则从视觉特征中自适应汇聚少量 Token [?]. BLIP-2 在冻结图像编码器和语言模型之间加入 Q-Former, 用一组可学习 Query 把视觉特征压缩为固定长度的表示 [11]。InstructBLIP 让指令参与 Q-Former 计算, 得到随指令变化的视觉表示 [3]。两者关注通用视觉语言模型的模态连接与指令调优。QDPT 面对的是已有 MLLM 的轻量领域适配: Query 由完整问题生成, 从冻结视觉编码器的中间层读取证据, 输出则作为动态 LLM Prompt。

DRAPE 根据当前指令构造 Query, 对视觉特征执行跨模态注意力, 并生成实例级 LLM Soft Prompt [8]。该方法面向多模态持续指令学习, 包含任务路由和任务相关 Prompt 生成器, 并更新共享视觉投影模块。GRASP 面向遥感 MLLM 适配, 用问题表示计算区域相关性, 再通过稀疏权重组合区域 Prompt 原型 [17]。这两项工作与 QDPT 在方法上更接近。QDPT 采用完全冻结的骨干, 从视觉编码器中间层读取实际图像特征, 并把静态领域 Prompt 与问题条件的动态 Prompt 分开建模。

2.3 专业视觉领域中的多模态模型

专业视觉任务有自己的图像分布和问题体系。PathVQA [5] 和 SLAKE [14] 提供了公开的医学视觉问答数据与开放式、封闭式评价协议。CoTBox-TTT 使用视觉思维链框定位问题相关区域, 并在测试阶段逐样本优化 Evidence Prompt 和 Answer Prompt [15]。QDPT 不做测试时训练; 其适配器在训练集上学习, 推理时直接生成 Prompt。

电力与工业视觉也需要领域适配。Power-LLaVA 用于输电线路巡检 [20], 另有工作评估多模态大模型对电网资产的检查能力 [4, 16]。DefectGPT 研究有限电气样本下的多类别缺陷识别 [13], 动态 LoRA 路由则被用于光伏故障诊断 [21]。这些论文与 QDPT 接近的是应用场景, 而不是动态 Prompt 机制。本文先在公开 VQA 基准上进行可复现实验, 后续再用电力电气数据检验跨领域表

现。

3 方法

3.1 问题定义与冻结设置

给定领域视觉问答数据集 $\mathcal{D} = \{(I_i, X_i, Y_i)\}_{i=1}^N$ ，其中 I_i 为输入图像， X_i 为问题文本， Y_i 为目标答案。本文使用 Qwen3-VL[2] 作为基础模型，并将其记为 F_Φ ；参数 Φ 包括视觉编码器、视觉 Merger 和自回归语言模型。QDPT 固定 Φ ，只训练新增的 Prompt、投影层和跨模态注意力参数 Θ 。优化目标是答案 Token 上的自回归负对数似然：

$$\mathcal{L}(\Theta) = - \sum_{i=1}^N \sum_{t=1}^{|Y_i|} \log p_{\Phi, \Theta}(y_{i,t} \mid I_i, X_i, Y_{i,<t}), \quad \Phi \text{ 保持冻结}. \quad (1)$$

冻结的是骨干参数，而不是前向计算。可训练 Prompt 进入视觉编码器或 LLM 后，仍会改变后续 Token 的激活。

3.2 总体结构

图 1给出了 QDPT 的总体结构，以下视觉层编号采用代码索引。图像先经过冻结视觉编码器的第 0 至 16 层。模型在第 17 层加入静态视觉 Prompt；该层计算结束后移除 Prompt 对应的输出，图像 Token 继续通过第 18 至 23 层和 Merger。与此同时，QDPT 用完整问题生成 10 个 Query，以进入第 17 层前的图像 Token 作为视觉 K/V，计算 Directional Workspace。映射层把所得表示转换为动态语言 Prompt。送入 LLM 时，静态语言 Prompt 位于视觉 Token 之前，动态 Prompt 位于视觉 Token 与问题之间。

静态 Prompt 由所有样本共享，用于学习领域信息；Directional Workspace 根据当前问题和图像生成动态表示。动态表示进入 LLM，不再送回视觉编码器。视觉侧的适配由静态 Prompt 完成。

3.3 静态领域校准

设第 0 至 16 个视觉 Block 输出的原始图像 Token 为 $H^v \in \mathbb{R}^{n_v \times d_v}$ 。QDPT 采用视觉 Prompt Tuning 的连续 Token 形式 [9]，维护 18 个可训练视觉 Prompt $P^v \in \mathbb{R}^{18 \times d_v}$ ，并在第 17 个视觉 Block 前执行

$$\tilde{H}^v = \text{Block}_{17}([P^v; H^v]). \quad (2)$$

该层输出中与 P^v 对应的 18 个 Token 被丢弃，图像 Token 继续经过第 18 至 23 个视觉 Block 和 Merger。静态 Prompt 会影响后续图像表示，但不会增加 Merger 和 LLM 接收的视觉序列长度。

实现中，18 个视觉 Prompt 按学习率分为 8 个和 10 个 Token，两组没有预先指定的语义分工，正文统一记为 P^v 。语言侧另有 20 个连续 Prompt Token[10]，记为 $P^t \in \mathbb{R}^{20 \times d_l}$ ，其中 d_l 为 LLM 隐藏维度。 P^v 作用于视觉编码器， P^t 直接进入 LLM 输入序列。




图 1: QDPT 总体结构。静态视觉 Prompt 在第 17 个视觉 Block 中提供领域校准，并在该层之后移除；问题条件的 Directional Workspace 只读取视觉证据，经语言侧映射生成动态 Prompt。图中的 Multimodal Workspace 对应本文所称的 Directional Workspace。




图 2: Directional Workspace 的构造。完整问题 Token 经可训练评分向量和 Value Projection 形成问题 Query；第 17 层之前的视觉 Token 投影为 K/V。Cross-Attention 读取与问题相关的视觉证据，并通过残差连接得到共享表示。

3.4 问题引导的 Directional Workspace

图 2 展开了 Directional Workspace 的计算过程。设完整问题经过冻结词嵌入层后得到 $H^q \in \mathbb{R}^{n_q \times d_l}$ 。QDPT 使用 $m = 10$ 个可训练评分向量对全部问题 Token 执行注意力池化，从同一问题中产生 10 个 Query。记评分矩阵为 $R \in \mathbb{R}^{m \times d_l}$ ，问题值投影为 $W_q \in \mathbb{R}^{d_l \times D}$ ，则

$$A^q = \text{softmax}\left(R(H^q)^\top\right), \quad (3)$$

$$Q = A^q(H^q W_q), \quad (4)$$

其中 Softmax 沿问题 Token 维计算，Padding 位置在归一化前被屏蔽， $Q \in \mathbb{R}^{m \times D}$ 。各评分向量独立聚合问题 Token，训练前不指定槽位含义。

视觉 K/V 来自同一样本的 H^v ，而不是静态视觉 Prompt 或 Merger 后的压缩表示。通过可训练投影 $W_k, W_v \in \mathbb{R}^{d_v \times D}$ 得到

$$K = H^v W_k, \quad V = H^v W_v. \quad (5)$$

以问题表示检索图像区域是视觉问答中的常见建模方式 [? ?]。QDPT 采用 16 头 Cross-Attention[19]，以问题表示为 Query、图像表示为 K/V：

$$O = \text{MHA}(Q, K, V), \quad (6)$$

$$Z = Q + O, \quad (7)$$

其中 $Z \in \mathbb{R}^{m \times D}$ 即 Directional Workspace。宽度 D 控制问题投影、视觉投影和跨模态注意力的容量。本文最终配置取 $D = 768$ ，后续实验均以该配置为主模型。

“Directional”指两种模态在注意力中的固定角色：问题 Token 形成 Query，图像 Token 只作为 K/V。输出 Z 用于生成语言 Prompt，不参与视觉编码器后续各层的计算。

3.5 动态语言 Prompt

Directional Workspace 通过映射函数 $g_\theta : \mathbb{R}^D \rightarrow \mathbb{R}^{d_l}$ 逐槽转换为语言侧残差：

$$\Delta P^d = g_\theta(Z). \quad (8)$$

参考零初始化适配器的做法 [?]， g_θ 的输出层在训练开始时置零，因此初始动态残差为零。模型另维护 10 个静态可训练 Anchor $A^t \in \mathbb{R}^{m \times d_l}$ ，最终动态 Prompt 为

$$P^d = A^t + \Delta P^d. \quad (9)$$

由于输出层从零开始训练，初始状态下 $P^d = A^t$ ；训练后，样本差异由 ΔP^d 表示。记 Merger 输出的视觉表示为 $M(I)$ ，原始文本 Token 为 $T(X)$ 。下一小节说明它们在 LLM 输入中的排列顺序。

当前密集配置包含 20 个静态语言 Prompt 和 10 个问题条件动态 Prompt。推理时，动态分支执行问题池化、视觉 Cross-Attention 和 Prompt 映射，不针对测试样本进行反向传播。

3.6 Prompt 放置与因果可见性

自回归 LLM 中的 Token 顺序会改变各类 Prompt 能够影响的后续表示。QDPT 采用图 3 所示的 Sandwich 顺序，将静态领域 Prompt 放在视觉 Token 之前，将问题条件的动态 Prompt 放在视觉 Token 之后、问题 Token 之前。对应的输入序列为

$$E_{\text{LLM}} = [P^t; M(I); P^d; T(X)]. \quad (10)$$




图 3: QDPT 在冻结因果 LLM 中的 Prompt 放置。静态 Prompt 位于视觉 Token 之前，用作领域先验；问题引导的证据 Prompt 位于视觉 Token 之后并紧邻问题。箭头表示由因果掩码决定的前向可见方向。

静态 Prompt 位于序列前部，后续视觉 Token、动态 Prompt 和问题 Token 都能在 LLM 自注意力中访问它。动态 Prompt 由当前图像与问题共同生成，放在视觉 Token 之后，可以在 LLM 内部继续结合前面的静态 Prompt 和视觉表示；问题及答案 Token 则能访问动态 Prompt。若将静态 Prompt 移到视觉 Token 之后，因果掩码会阻止它影响前面的视觉表示。本文在模型、训练协议和 Prompt 数量不变的条件下比较不同排列，结果见实验部分。

3.7 参数规模与适配路径

训练时只更新 QDPT 适配器，视觉编码器、Merger、词嵌入层和 LLM 均保持冻结。本文采用的 D768 密集配置共有 7,805,184 个可训练参数，具体组成见表 1。静态语言 Prompt、动态 Prompt Anchor 和静态视觉 Prompt 合计 95,232 个参数，占适配器的 1.22%；其余 7,709,952 个参数用于问题池化、视觉 K/V 投影、16 头 Cross-Attention 和动态 Prompt 输出头。

表 1: QDPT-D768 密集配置的可训练参数组成。

模块	配置	参数量
静态语言 Prompt P^t	20×2560	51,200
动态 Prompt Anchor A^t	10×2560	25,600
静态视觉 Prompt P^v	18×1024	18,432
问题池化、跨模态检索与输出头	$D = 768$	7,709,952
合计		7,805,184

动态生成器的参数量主要由宽度 D 和输出头决定。实验部分在 D768 结构内比较密集输出头与秩 256 压缩输出头；该对照只改变输出映射容量，不引入此前结构探索阶段的非 Sandwich 配置。适配器文件变小也不意味着训练时间会等比例缩短，因为冻结骨干仍需完成前向计算并参与梯度回传。

对每个样本，问题表示从视觉 K/V 中聚合与当前问题相关的证据，形成动态表示 Z ；输出头 g_θ 再将 Z 映射为 10 个 Prompt Token，并插入 LLM 输入序列。 Z 不返回视觉编码器。视觉编码阶段只引入 18 个由所有样本共享的静态 Prompt，样本相关的动态表示则用于调整语言模型的输入上下文。

4 实验

本章在同一冻结骨干和评价脚本下比较 QDPT、静态 Prompt、实例条件 Prompt 与 LoRA。所有 QDPT 主结果均来自最终的 D768 Sandwich 配置；此前用于结构探索的非 Sandwich 结果不纳入正文。唯一例外是 Prompt 位置消融，该实验直接比较三种输入顺序，用于说明 Sandwich 设计的依据。

4.1 实验设置

4.1.1 数据集

视觉问答要求模型根据图像和自然语言问题生成答案 [?]。PathVQA[5] 是主要开发数据集。结构选择在官方 Validation 划分上完成，Test 划分仅用于最终配置的评估。本文同时报告 Overall、Yes/No 和 Free-form 准确率，以区分封闭式判断与开放式生成。

SLAKE[14] 用于检查同一结构在另一数据集上的表现。QDPT 沿用在 PathVQA 上确定的 Prompt 长度、视觉层和适配宽度，不根据 SLAKE 结果重新搜索结构。除 Overall 外，实验还统计 CLOSED 与 OPEN、KVQA 与 VQA，以及英文和中文问题。

自建电力电气数据集用于专业场景验证。实验采用固定留出集和统一评价脚本，每种方法均得到 954 条有效预测，另有 18 条样本因数据问题跳过。由于当前只保留总体准确率，且 QDPT 只运行一个随机种子，该部分按应用案例报告，不作统计显著性或同领域最优声明。

4.1.2 比较方法

所有方法使用同一 Qwen3-VL 骨干 [2]、图像预处理和答案评估脚本。Static LLM Prompt、Static Visual Prompt 与 Dual Static Prompt 分别在语言侧、视觉侧或两侧加入样本共享的连续 Prompt[9, 10]。CoCoOp-style 根据图像均值特征生成语言 Prompt，其条件化思路来自 CoCoOp[22]，但这里将其改写为适用于生成式 MLLM 的受控基线。GRASP 按照论文描述独立实现 [17]；表中的数字来自本文统一三轮协议，不是 GRASP 论文报告的遥感结果。Full-Attention LoRA-r8[7] 在语言模型全部注意力层加入秩为 8 的低秩更新，作为权重空间适配参照。

4.1.3 训练与评价协议

QDPT 冻结视觉编码器、Merger、词嵌入层和 LLM，只更新第 3 节定义的适配器。主要实验训练三个 Epoch，有效 Batch Size 为 32。多随机种子实验使用 44、45 和 46；单次对照默认使用 seed 44。电气数据集使用训练 seed 47 和数据划分 seed 42。

表 2: PathVQA Validation 上的受控比较 (%)。三次运行报告均值 $\pm$ 标准差；单次运行报告点估计。GRASP 为统一三轮协议下的独立实现。

方法	参数量	种子数	Overall	Yes/No	Free-form
Static Visual Prompt	20,480	1	35.9482	68.7040	3.2865
Dual Static Prompt	71,680	1	54.6253	88.3840	20.9636
Static LLM Prompt	51,200	3	55.0780 $\pm$ 0.2244	88.9493 $\pm$ 0.5509	21.3040 $\pm$ 0.9117
CoCoOp-style	873,120	3	56.3136 $\pm$ 1.1367	89.3547 $\pm$ 0.5903	23.3674 $\pm$ 1.6913
GRASP (independent impl.)	2,632,704	1	39.7508	75.3600	4.2438
QDPT-D768 Sandwich	7,805,184	3	59.1522 $\pm$ 1.7528	91.6480 $\pm$ 1.0300	26.7496 $\pm$ 2.5107
Full-Attention LoRA-r8	7,077,888	3	59.2640 $\pm$ 0.0666	91.7227 $\pm$ 0.4077	26.8986 $\pm$ 0.2836

表 3: PathVQA Test 结果 (%)。QDPT 仅使用最终 D768 Sandwich 配置。

方法	种子数	Overall	Yes/No	Free-form
Frozen Base	1	34.7700	67.3400	2.1400
Static LLM Prompt	1	55.8268	90.3331	21.2690
QDPT-D768 Sandwich	3	58.8827 $\pm$ 1.8141	91.3246 $\pm$ 1.1491	26.3926 $\pm$ 2.4909

主指标为答案归一化后的 Exact Match 准确率。三次运行以均值 $\pm$ 样本标准差报告，只有一次运行的方法直接给出点估计，并在表中标出种子数。运行时间只比较相同实现环境和计时口径下的结果。对于缺少逐题预测或重复运行的实验，本文不报告置信区间，也不据点估计判断统计显著性。

4.2 PathVQA 结果

4.2.1 Validation 上的受控比较

表 2 汇总 PathVQA Validation 结果。最终 QDPT 的三随机种子平均 Overall 为 59.1522，与 LoRA-r8 的 59.2640 相差 0.1118 个百分点，二者在当前协议下基本持平。QDPT 高于 Static LLM Prompt 和 CoCoOp-style，但其标准差也更大。单次运行中，Static Visual Prompt 只有 3.2865 的 Free-form 准确率；同时在视觉侧和语言侧加入静态 Prompt 后，Dual Static Prompt 的 Overall 升至 54.6253。GRASP 独立实现的结果较低，说明该方法在原任务之外的直接迁移并不稳定；这一数字不能视为 GRASP 的官方复现结果。

4.2.2 最终 Test 结果

结构确定后，最终 QDPT 在 PathVQA Test 上运行三个随机种子，结果见表??。其平均 Overall 为 58.8827，较 Static LLM Prompt 的单次结果高 3.0559 个百分点；提升主要来自 Free-form 问题。由于 Static LLM Prompt 只运行一次，这里的差值是描述性比较，不用于方差或显著性判断。

表 4: SLAKE Test 结果 (%). 三次运行报告均值 $\pm$ 标准差。

方法	种子数	Overall	CLOSED	OPEN	KVQA	VQA	EN	ZH
Static LLM Prompt	1	74.40	80.62	70.27	62.55	76.14	75.40	73.38
QDPT-D768 Sandwich	3	76.95 $\pm$ 0.44	84.01 $\pm$ 1.32	72.26 $\pm$ 1.14	62.17 $\pm$ 0.00	79.11 $\pm$ 0.51	77.51 $\pm$ 1.44	76.38 $\pm$ 0.64
Full-Attention LoRA-r8	3	81.82 $\pm$ 0.22	87.00 $\pm$ 0.39	78.38 $\pm$ 0.62	70.41 $\pm$ 1.72	83.49 $\pm$ 0.08	82.85 $\pm$ 0.41	80.77 $\pm$ 0.05

表 5: 自建电力电气数据集固定留出集结果 (%). 每种方法均为单次运行, 共 954 条有效预测。

方法	可训练参数	Overall
Static LLM Prompt	51,200	70.06
CoCoOp-style	873,120	70.88
Full-Attention LoRA-r8	7,077,888	70.69
QDPT-D768 Sandwich	7,805,184	71.91

4.3 SLAKE 跨数据集结果

表??给出 SLAKE Test 结果。QDPT 的平均 Overall 为 76.95, 高于 Static LLM Prompt 的单次结果 74.40, 在 OPEN、VQA 及中英文子集上也取得更高点估计。LoRA-r8 达到 81.82, 比 QDPT 高 4.87 个百分点, 并在各项拆分上保持优势。因此, PathVQA 上的接近结果不能推广为 QDPT 与 LoRA 在不同数据集上普遍相当。SLAKE 包含知识型问题和双语问题, 权重空间适配在这类任务上仍有明显优势。

4.4 电力电气数据集结果

固定留出集上的结果列于表??. 最终 QDPT 得到 71.91 的总体准确率, 分别比 Static LLM Prompt、CoCoOp-style 和 LoRA-r8 高 1.85、1.03 和 1.22 个百分点。这组结果说明 QDPT 可以迁移到非医学的专业图像, 但证据范围有限: 所有方法只有一次运行, 当前记录也没有类别拆分或逐题置信区间。

4.5 Prompt 放置位置消融

因果 LLM 只能访问当前位置之前的 Token, 三类 Prompt 的排列会改变信息传播路径。表 5 固定模型、参数量、初始化和训练协议, 只调整输入顺序。Sandwich 取得 60.7765 的 Overall; 将两类 Prompt 都放在视觉 Token 之后时, Overall 下降 1.5178 个百分点; 交换静态与动态 Prompt 的位置后, 下降 2.6522 个百分点。三项实验均使用 seed 44, 因此这里只比较点估计, 不使用“显著提升”等统计表述。

4.6 输出头容量与训练效率

QDPT-Lite 保留 D768 的 Workspace, 但把动态 Prompt 输出头压缩到秩 256。表??显示, 该改动减少 21.84% 的可训练参数, 同时使 Overall 下降 3.3552 个百分点, Free-form 下降 4.7556 个

表 6: PathVQA Validation 上的 Prompt 放置位置消融 (seed 44, %)。三种配置均含 7,805,184 个可训练参数。

输入顺序	Overall	Yes/No	Free-form	Δ Overall
$[P^t; M(I); P^d; T(X)]$ (Sandwich)	60.7765	92.7360	28.9100	0.0000
$[M(I); P^t; P^d; T(X)]$	59.2587	91.6160	26.9943	-1.5178
$[P^d; M(I); P^t; T(X)]$	58.1243	91.4880	24.8564	-2.6522

表 7: PathVQA Validation 上的动态 Prompt 输出头容量对照 (seed 44, %)。

配置	可训练参数	Overall	Yes/No	Free-form
QDPT-D768 Dense	7,805,184	60.7765	92.7360	28.9100
QDPT-D768/R256	6,100,736	57.4213	90.7840	24.1544

百分点。输出头压缩在当前配置下并非近似无损，因此本文不把该变体作为主模型或效率版本。

训练耗时见表??。PathVQA 只比较具有相同记录口径的 seed 45 和 46，QDPT 平均用时 6629.11 秒，LoRA-r8 为 14848.75 秒，前者约快 2.24 倍。SLAKE 三随机种子的平均训练时间分别为 4739.96 秒和 7039.16 秒，约相差 1.49 倍。SLAKE 推理中，QDPT 的 TTFT 和 TPOT 也略低。速度差异来自当前软硬件环境与具体实现，不代表参数量与端到端耗时存在固定比例。

4.7 随机种子稳定性

表??列出 PathVQA Validation 上的三随机种子结果。LoRA-r8 的标准差为 0.0666，Static LLM Prompt 为 0.2244；两个实例条件 Prompt 方法的波动更大，CoCoOp-style 和 QDPT 分别为 1.1367 与 1.7528。QDPT 的 seed 44 结果最高，但其三次运行范围达到 3.4830 个百分点，只报告该次结果会高估方法的典型表现。这个现象目前限于 Qwen3-VL 与 PathVQA 的组合，不能据此推断所有动态 Prompt 都不稳定。

4.8 结果边界

三组数据呈现出不同结论。QDPT 在 PathVQA 上与 LoRA-r8 接近，在 SLAKE 上落后 4.87 个百分点，在电力电气留出集上则取得最高点估计。较短的训练时间是 QDPT 的实际优势，但其可训练参数量并不低于本实验中的 LoRA-r8，且 PathVQA 上的随机种子波动较大。现有结果支持把 QDPT 看作冻结 MLLM 的一种可选适配路径，而不是对 LoRA 的普遍替代。

本文仍缺少公开电力数据集上的复现实验，私有数据也尚未提供类别级分析。后续定稿应补全数据集说明和软硬件环境；如果保留统计显著性讨论，还需基于逐题预测统一计算置信区间与配对检验。

表 8: QDPT 与 LoRA-r8 的实测效率。PathVQA 训练时间为 seed 45/46 均值, SLAKE 为三个随机种子均值。

数据集	方法	训练时间 (s)	TTFT (s)	TPOT (s/token)
PathVQA	QDPT-D768 Sandwich	6629.11	–	–
PathVQA	Full-Attention LoRA-r8	14848.75	–	–
SLAKE	QDPT-D768 Sandwich	4739.96	0.067779	0.020091
SLAKE	Full-Attention LoRA-r8	7039.16	0.071839	0.024217

表 9: PathVQA Validation Overall 的随机种子稳定性 (%)。

方法	Seed 44	Seed 45	Seed 46	Mean $\pm$ SD	Range
Full-Attention LoRA-r8	59.3386	59.2427	59.2107	59.2640 $\pm$ 0.0666	0.1279
Static LLM Prompt	54.8650	55.0567	55.3124	55.0780 $\pm$ 0.2244	0.4474
CoCoOp-style	57.4053	56.3988	55.1366	56.3136 $\pm$ 1.1367	2.2687
QDPT-D768 Sandwich	60.7765	57.2935	59.3865	59.1522 $\pm$ 1.7528	3.4830

参考文献

- [1] Jean-Baptiste Alayrac, Jeff Donahue, Pauline Luc, Antoine Miech, Iain Barr, Yana Hasson, Karel Lenc, Arthur Mensch, Katie Millican, Malcolm Reynolds, Roman Ring, Eliza Rutherford, Serkan Cabi, Tengda Han, Zhitao Gong, Sina Samangooei, Marianne Monteiro, Jacob Menick, Sebastian Borgeaud, Andy Brock, Aida Nematzadeh, Sahand Sharifzadeh, Mikolaj Binkowski, Ricardo Barreira, Oriol Vinyals, Andrew Zisserman, and Karen Simonyan. Flamingo: A visual language model for few-shot learning. In *Advances in Neural Information Processing Systems*, 2022. URL <https://arxiv.org/abs/2204.14198>.
- [2] Shuai Bai, Yuxuan Cai, Rui-Zhe Chen, Keqin Chen, Xiong-Hui Chen, Zesen Cheng, Liang-Hao Deng, Wei Ding, Rongyao Fang, Chang Gao, Chunjiang Ge, Wenbin Ge, Zhifang Guo, Qidong Huang, Fei Huang, Binyuan Hui, Shutong Jiang, Zhaohai Li, Ming-Sheng Li, Mei Li, Kaixin Li, Zicheng Lin, Junyang Lin, Xue-Jing Liu, Jiawei Liu, Chenglong Liu, Yang Liu, Dayiheng Liu, Shixuan Liu, Dunjie Lu, Ruilin Luo, Chenxu Lv, Rui Men, Li Ying Meng, Lingchen Meng, Xin-Yi Ren, Sibao Song, Yu-Chen Sun, Jun Tang, Jianhong Tu, Jianqiang Wan, Peng Wang, Pengfei Wang, Qiuyue Wang, Yuxuan Wang, Tianbao Xie, Yihe Xu, Haiyang Xu, Jin Xu, Zhibo Yang, Mingkun Yang, Jianxin Yang, An Yang, Bowen Yu, Fei Zhang, Hang Zhang, Xi Zhang, Botao Zheng, Humen Zhong, Jingren Zhou, Fanxi Zhou, Yuanzhi Zhu, and Keming Zhu. Qwen3-VL technical report. *arXiv preprint arXiv:2511.21631*, 2025. URL <https://arxiv.org/abs/2511.21631>.
- [3] Wenliang Dai, Junnan Li, Dongxu Li, Anthony Tiong, Junqi Zhao, Weisheng Wang, Boyang Li, Pascale N. Fung, and Steven C. H. Hoi. InstructBLIP: Towards general-purpose vision-language models with instruction tuning. *Advances in Neural Information Processing Systems*, 36:49250–49267, 2023.
- [4] Jingbo Hao and Yang Tao. Power grid inspection based on multimodal foundation models. *EAI Endorsed Transactions on Energy Web*, 12, 2025. URL <https://api.semanticscholar.org/CorpusID:277801118>.
- [5] Xuehai He, Yichen Zhang, Luntian Mou, Eric P. Xing, and Pengtao Xie. PathVQA: 30000+ questions for medical visual question answering. *arXiv preprint arXiv:2003.10286*, 2020. URL <https://arxiv.org/abs/2003.10286>.
- [6] Neil Houlsby, Andrei Giurgiu, Stanislaw Jastrzebski, Bruna Morrone, Quentin de Laroussilhe, Andrea Gesmundo, Mona Attariyan, and Sylvain Gelly. Parameter-efficient transfer learning for NLP. In *Proceedings of the 36th International Conference on Machine Learning*, pages 2790–2799. PMLR, 2019.

- [7] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Liang Wang, and Weizhu Chen. LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations (ICLR)*, 2022. URL <https://arxiv.org/abs/2106.09685>.
- [8] Tao Hu and Da-Wei Zhou. Dynamic cross-modal prompt generation for multi-modal continual instruction tuning. *arXiv preprint arXiv:2605.10765*, 2026. URL <https://arxiv.org/abs/2605.10765>.
- [9] Menglin Jia, Luming Tang, Bor-Chun Chen, Claire Cardie, Serge Belongie, Bharath Hariharan, and Ser-Nam Lim. Visual prompt tuning. In *European Conference on Computer Vision*, pages 709–727. Springer, 2022.
- [10] Brian Lester, Rami Al-Rfou, and Noah Constant. The power of scale for parameter-efficient prompt tuning. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pages 3045–3059, 2021.
- [11] Junnan Li, Dongxu Li, Silvio Savarese, and Steven C. H. Hoi. BLIP-2: Bootstrapping language-image pre-training with frozen image encoders and large language models. In *Proceedings of the 40th International Conference on Machine Learning*, pages 19730–19742. PMLR, 2023.
- [12] Xiang Lisa Li and Percy Liang. Prefix-tuning: Optimizing continuous prompts for generation. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing*, pages 4582–4597, 2021.
- [13] Zhuoyi Lin, Kaixin Xu, Aye Phyu Phyu Aung, Wen Qiu, Bernice Zee, Jiann Min Chin, and Senthilnath Jayavelu. DefectGPT: Towards multi-class defect detection with limited electrical samples. In *Proceedings of the British Machine Vision Conference (BMVC)*, 2025.
- [14] Bo Liu, Li-Ming Zhan, Li Xu, Lingxing Ma, Yan Yang, and Xiao-Ming Wu. SLAKE: A semantically-labeled knowledge-enhanced dataset for medical visual question answering. In *2021 IEEE 18th International Symposium on Biomedical Imaging (ISBI)*, pages 1650–1654, 2021. URL <https://api.semanticscholar.org/CorpusID:231951663>.
- [15] Jiahe Qian, Yuhao Shen, Zhangtianyi Chen, Juexiao Zhou, and Peisong Wang. CoTBox-TTT: Grounding medical VQA with visual chain-of-thought boxes during test-time training. *arXiv preprint arXiv:2511.12446*, 2025. URL <https://arxiv.org/abs/2511.12446>.
- [16] Pedro Daniel Rocha, Fernando J. P. Lopes, and Luís Alberto da Silva Cruz. Advances in electrical grid assets inspection: Exploring multimodal large language models. In *2025*

- 25th International Conference on Digital Signal Processing (DSP)*, pages 1–5, 2025. URL <https://api.semanticscholar.org/CorpusID:280164358>.
- [17] Qigan Sun, Chaoning Zhang, Jianwei Zhang, Xudong Wang, Jiehui Xie, Pengcheng Zheng, Haoyu Wang, Sungyoung Lee, Chi-lok Andy Tai, Yang Yang, and Heng Tao Shen. GRASP: Guided region-aware sparse prompting for adapting MLLMs to remote sensing. *arXiv preprint arXiv:2601.17089*, 2026. URL <https://api.semanticscholar.org/CorpusID:285051752>.
- [18] Yi-Lin Sung, Jaemin Cho, and Mohit Bansal. VL-Adapter: Parameter-efficient transfer learning for vision-and-language tasks. *arXiv preprint arXiv:2112.06825*, 2021. URL <https://arxiv.org/abs/2112.06825>.
- [19] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, 2017. URL <https://api.semanticscholar.org/CorpusID:13756489>.
- [20] Jiahao Wang, Mingxuan Li, Haichen Luo, Jinguo Zhu, Aijun Yang, Mingzhe Rong, and Xiaohua Wang. Power-LLaVA: Large language and vision assistant for power transmission line inspection. In *2024 IEEE International Conference on Image Processing (ICIP)*, pages 963–969, 2024. URL <https://arxiv.org/abs/2407.19178>.
- [21] Jun Wu, Yiwei Chen, Qihao Min, Ming Chen, Jie Zhao, and Mang Ye. Domain-adaptive multimodal large language models for photovoltaic fault diagnosis via dynamic LoRA routing. *Processes*, 14(4):653, 2026. URL <https://api.semanticscholar.org/CorpusID:285620821>.
- [22] Kaiyang Zhou, Jingkang Yang, Chen Change Loy, and Ziwei Liu. Conditional prompt learning for vision-language models. In *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 16795–16804, 2022. URL <https://api.semanticscholar.org/CorpusID:247363011>.
- [23] Xionghao Zhou, Jie He, Yuhua Ke, Guangyao Zhu, Víctor Gutiérrez-Basulto, and Jeff Z. Pan. An empirical study on parameter-efficient fine-tuning for multimodal large language models. In *Findings of the Association for Computational Linguistics: ACL 2024*, pages 10057–10084, 2024.