

Question-Guided Directional Prompting for Parameter-Efficient Domain Adaptation of Frozen Multimodal Large Language Models

Abstract

Adapting multimodal large language models to specialized visual domains often requires a separate set of trainable parameters for each domain. We present Question-Guided Directional Prompt Tuning (QDPT), a parameter-efficient method that keeps the multimodal backbone frozen. QDPT uses the current question to query intermediate visual features and maps the retrieved evidence to dynamic language prompts. Shared visual and language prompts retain domain-level information, while the dynamic branch represents the correspondence between each question and image. Experiments on two public visual question answering benchmarks compare QDPT with static prompt tuning, conditional prompt baselines, and low-rank weight adaptation.

Keywords: multimodal large language models, parameter-efficient fine-tuning, dynamic prompt tuning, visual question answering, domain adaptation

1 引言

多模态大语言模型已经能够接收图像与文本输入，并以生成方式完成开放式问答[1–3]。LLaVA和MiniGPT-4进一步表明，视觉指令调优可以把预训练视觉模块与大语言模型用于多轮图文交互[4, 5]。但将通用模型用于专业领域时，通常仍需针对新的图像分布和任务语言进行适配。医学视觉问答与电力设备巡检中的现有工作都反映了这类需求[6–8]。以设备图像为例，问题可能分别询问部件类别、连接关系或异常位置；即使图像相同，模型需要读取的证据也会随问题变化。完整微调需要更新并保存整套模型参数，多领域部署时还要为各领域维护独立权重，因此训练和存储成本都较高[9, 10]。

参数高效微调只更新一小部分新增参数。LoRA用低秩矩阵表示权重增量[10]，IA³通过缩放中间激活完成适配，AdaLoRA则在训练中分配低秩更新的参数预算[11, 12]。Prefix Tuning和Prompt Tuning保持骨干权重冻结，优化连续的前缀或输入Token[13, 14]；P-Tuning v2将连续Prompt扩展到更深的网络层[15]，类似思路也被用于视觉模型[16]。Prompt方法的适配参数容易按领域单独保存，但传统Soft Prompt通常对所有样本使用同一组Token。它能学习训练集共享的任务信息，却不会根据当前问题重新选择图像证据。视觉问答恰好需要这种选择：同一张图像对应不同问题时，相关区域和属性也会改变[17]。

条件Prompt为每个样本生成不同的上下文。在CLIP[18]基础上，CoOp学习任务共享的连续上下文[19]，CoCoOp进一步根据图像特征产生实例条件Token[20]；MaPLe则在视觉和语言分支中联合学习Prompt[21]。DRAPE结合当前指令与视觉特征生成动态Soft Prompt[22]。另一条相关路线以少量潜在表示汇聚高维输入[23, 24]：BLIP-2的Q-Former从冻结图像编码器中提取固定长度的视觉表示，InstructBLIP进一步让指令参与这一过程[2, 17]。这些工作给出了可用的技术部件，但对于冻结生成式多模态大模型的领域适配，仍需确定从哪一层读取视觉证据、静态Prompt和动态Prompt如何分工，以及动态表示最终应放在模型的哪个位置。

本文研究Question-Guided Directional Prompt Tuning (QDPT)，一种面向冻结多模态大语言模型的样本条件Prompt适配方法。QDPT使用当前问题生成一组查询，以视觉编码器中间层的图像Token作为键和值，通过定向跨模态注意力提取与问题相关的证据，再将所得表示映射为语言模型侧的动态Prompt。模型同时保留静态Prompt，用于学习领域级的共享校准。两类Prompt承担不同作用：静态部分描述跨样本重复出现的领域信息，动态部分则根据当前图像和问题改变。训练过程中，视觉编码器、视觉投影模块和语言模型的原有权重均保持冻结。

QDPT采用非对称的信息路径。问题描述检索目标，图像提供候选证据，匹配后的表示在语言模型入口形成动态Prompt。视觉编码器的后续计算沿用静态Prompt校准后的视觉Token，动态分支不再改写这一路径。跨模态适配宽度 D 用于控制问题投影、视觉投影和Cross-Attention的容量。

我们在PathVQA[6]和SLAKE[7]上检验QDPT，并在统一骨干和评价脚本下与静态Prompt、CoCoOp-style Prompt及LoRA[10, 20]比较。PathVQA上，QDPT的三随机种子平均结果与Full-Attention LoRA-r8接近；SLAKE上，LoRA高出4.87个百分点。自建电力电气数据集提供了另一类专业图像上的验证，QDPT在固定留出集上取得71.91的最高准确率。QDPT在PathVQA和SLAKE上的训练速度分别约为LoRA-r8的2.24倍和1.49倍。

Prompt的位置直接影响因果LLM中的信息传播。固定参数量与训练设置后，QDPT采用的 $[P^t; M(I); P^d; T(X)]$ 顺序优于两种位置对照。将动态Prompt输出头压缩至秩256可减少21.84%的可训练参数，Overall同时下降3.36个百分点。多随机种子实验中，QDPT在PathVQA上的波动高于静态Prompt和LoRA。本文据此从准确率、训练耗时和运行稳定性三个方面评价不同适配方法。

本文的主要贡献如下：

- 提出QDPT，在不更新多模态大模型骨干权重的条件下，用当前问题定向读取图像证据并生成样本相关的语言Prompt。
- 将样本共享的领域校准与问题条件的视觉证据提取分开，并为冻结的因果LLM设计静态Prompt、视觉Token与动态Prompt的输入顺序。
- 通过Prompt位置和输出头压缩实验分析结构选择，并用多随机种子结果报告动态Prompt的运行波动。
- 在两个公开VQA数据集和一个电力电气数据集上比较QDPT、静态Prompt、CoCoOp-style Prompt与LoRA，报告其准确率、训练耗时和跨数据集表现。

2 相关工作

2.1 多模态大模型的参数高效适配

参数高效微调通过限制可训练参数的范围，降低大模型适配和多任务部署的成本。Adapter在Transformer层之间加入小型可训练模块[9]，LoRA用低秩矩阵表示权重增量[10]。IA³学习作用于激活的缩放向量[11]，AdaLoRA则根据训练中的重要性分配低秩预算[12]。这些方法都保留预训练权重，但修改中间变换的方式不同。针对多模态大模型的实证研究表明，不同PEFT方法的效果与可训练模块所在位置密切相关，单看参数量不足以判断实际训练成本或任务性能[25]。

连续Prompt直接优化输入或中间表示。Prefix Tuning在Transformer各层引入可训练前缀[13]，Prompt Tuning优化输入侧的连续Token[14]，P-Tuning v2则把连续Prompt用于更深的网络层[15]。Visual Prompt Tuning[16]和VL-Adapter[26]将参数高效适配扩展到视觉及视觉语言任务，MaPLe进一步在视觉和语言分支之间耦合Prompt[21]。Prompt参数可以按领域单独保存，也不要求更新骨干权重。不过，多数静态Prompt对所有样本保持不变，适合记录任务或领域中的共享信息，却无法直接表达当前问题与图像之间的对应关系。QDPT保留静态Prompt，同时加入由当前样本生成的动态Prompt。

2.2 条件Prompt与问题引导的视觉聚合

条件Prompt根据输入为每个样本生成不同的上下文。CLIP通过自然语言监督建立图文共享表示[18]，CoOp在此基础上学习任务共享的连续上下文[19]。CoCoOp进一步使用图像特征生成实例条件Token，以减轻固定Prompt对训练类别的过拟合[20]，其输出仍服务于图像分类的文本表示。生成式视觉问答中的条件关系不同：问题限定检索目标，图像提供回答所需的证据。QDPT因此使用问题生成Query，而不是只用图像生成上下文。

Perceiver使用少量潜在向量通过Cross-Attention读取高维输入[23]，TokenLearner则从视觉特征中自适应汇聚少量Token[24]。BLIP-2在冻结图像编码器和语言模型之间加入Q-Former，用一组可学习Query把视觉特征压缩为固定长度的表示[2]。InstructBLIP让指令参与Q-Former计算，得到随指令变化的视觉表示[17]。两者关注通用视觉语言模型的模态连接与指令调优。QDPT面对的是已有MLLM的轻量领域适配：Query由完整问题生成，从冻结视觉编码器的中间层读取证据，输出则作为动态LLM Prompt。

DRAPE根据当前指令构造Query，对视觉特征执行跨模态注意力，并生成实例级LLM Soft Prompt[22]。该方法面向多模态持续指令学习，包含任务路由和任务相关Prompt生成器，并更新共享视觉投影模块。GRASP面向遥感MLLM适配，用问题表示计算区域相关性，再通过稀疏权重组合区域Prompt原型[27]。这两项工作与QDPT在方法上更接近。QDPT采用完全冻结的骨干，从视觉编码器中间层读取实际图像特征，并把静态领域Prompt与问题条件的动态Prompt分开建模。

2.3 专业视觉领域中的多模态模型

专业视觉任务有自己的图像分布和问题体系。PathVQA[6]和SLAKE[7]提供了公开的医学视觉问答数据与开放式、封闭式评价协议。CoTBox-TTT使用视觉思维链框定位问题相关区域，并在测试阶段逐样本优化Evidence Prompt和Answer Prompt[28]。QDPT不做测试时训练；其适配器在训练集上学习，推理时直接生成Prompt。




Fig. 1 QDPT总体结构。静态视觉Prompt在第17个视觉Block中提供领域校准，并在该层之后移除；问题条件的Directional Workspace只读取视觉证据，经语言侧映射生成动态Prompt。图中的Multimodal Workspace对应本文所称的Directional Workspace。

电力与工业视觉也需要领域适配。Power-LLaVA用于输电线路巡检[8]，另有工作评估多模态大模型对电网资产的检查能力[29, 30]。DefectGPT研究有限电气样本下的多类别缺陷识别[31]，动态LoRA路由则被用于光伏故障诊断[32]。这些论文与QDPT接近的是应用场景，而不是动态Prompt机制。本文先在公开VQA基准上进行可复现实验，后续再用电力电气数据检验跨领域表现。

3 方法

3.1 问题定义与冻结设置

给定领域视觉问答数据集 $\mathcal{D} = \{(I_i, X_i, Y_i)\}_{i=1}^N$ ，其中 I_i 为输入图像， X_i 为问题文本， Y_i 为目标答案。本文使用Qwen3-VL[3]作为基础模型，并将其记为 F_Φ ；参数 Φ 包括视觉编码器、视觉Merger和自回归语言模型。QDPT固定 Φ ，只训练新增的Prompt、投影层和跨模态注意力参数 Θ 。优化目标是答案Token上的自回归负对数似然：

$$\mathcal{L}(\Theta) = - \sum_{i=1}^N \sum_{t=1}^{|Y_i|} \log p_{\Phi, \Theta}(y_{i,t} | I_i, X_i, Y_{i, < t}), \quad \Phi \text{ 保持冻结}. \quad (1)$$

冻结的是骨干参数，而不是前向计算。可训练Prompt进入视觉编码器或LLM后，仍会改变后续Token的激活。

3.2 总体结构

图1给出了QDPT的总体结构，以下视觉层编号采用代码索引。图像先经过冻结视觉编码器的第0至16层。模型在第17层加入静态视觉Prompt；该层计算结束后移除Prompt对应的输出，图像Token继续通过第18至23层和Merger。与此同时，QDPT用完整问题生成10个Query，以进入第17层前的图像Token作为视觉K/V，计算Directional Workspace。映射层把所得表示转换为动态语言Prompt。送入LLM时，静态语言Prompt位于视觉Token之前，动态Prompt位于视觉Token与问题之间。




Fig. 2 Directional Workspace的构造。完整问题Token经可训练评分向量和Value Projection形成问题Query；第17层之前的视觉Token投影为K/V。Cross-Attention读取与问题相关的视觉证据，并通过残差连接得到共享表示。

静态Prompt由所有样本共享，用于学习领域信息；Directional Workspace根据当前问题和图像生成动态表示。动态表示进入LLM，不再送回视觉编码器。视觉侧的适配由静态Prompt完成。

3.3 静态领域校准

设第0至16个视觉Block输出的原始图像Token为 $H^v \in \mathbb{R}^{n_v \times d_v}$ 。QDPT采用视觉Prompt Tuning的连续Token形式[16]，维护18个可训练视觉Prompt $P^v \in \mathbb{R}^{18 \times d_v}$ ，并在第17个视觉Block前执行

$$\tilde{H}^v = \text{Block}_{17}([P^v; H^v]). \quad (2)$$

该层输出中与 P^v 对应的18个Token被丢弃，图像Token继续经过第18至23个视觉Block和Merger。静态Prompt会影响后续图像表示，但不会增加Merger和LLM接收的视觉序列长度。

实现中，18个视觉Prompt按学习率分为8个和10个Token，两组没有预先指定的语义分工，正文统一记为 P^v 。语言侧另有20个连续Prompt Token[14]，记为 $P^t \in \mathbb{R}^{20 \times d_t}$ ，其中 d_t 为LLM隐藏维度。 P^v 作用于视觉编码器， P^t 直接进入LLM输入序列。

3.4 问题引导的Directional Workspace

图2展开了Directional Workspace的计算过程。设完整问题经过冻结词嵌入层后得到 $H^q \in \mathbb{R}^{n_q \times d_t}$ 。QDPT使用 $m = 10$ 个可训练评分向量对全部问题Token执行注意力池化，从同一问题中产生10个Query。记评分矩阵为 $R \in \mathbb{R}^{m \times d_t}$ ，问题值投影为 $W_q \in \mathbb{R}^{d_t \times D}$ ，则

$$A^q = \text{softmax}(R(H^q)^\top), \quad (3)$$

$$Q = A^q(H^q W_q), \quad (4)$$

其中Softmax沿问题Token维计算，Padding位置在归一化前被屏蔽， $Q \in \mathbb{R}^{m \times D}$ 。各评分向量独立聚合问题Token，训练前不指定槽位含义。

视觉K/V来自同一样本的 H^v ，而不是静态视觉Prompt或Merger后的压缩表示。通过可训练投影 $W_k, W_v \in \mathbb{R}^{d_v \times D}$ 得到

$$K = H^v W_k, \quad V = H^v W_v. \quad (5)$$

以问题表示检索图像区域是视觉问答中的常见建模方式[33, 34]。QDPT采用16头Cross-Attention[35]，以问题表示为Query、图像表示为K/V：

$$O = \text{MHA}(Q, K, V), \quad (6)$$

$$Z = Q + O, \quad (7)$$

其中 $Z \in \mathbb{R}^{m \times D}$ 即Directional Workspace。宽度 D 控制问题投影、视觉投影和跨模态注意力的容量。本文最终配置取 $D = 768$ ，后续实验均以该配置为主模型。

“Directional”指两种模态在注意力中的固定角色：问题Token形成Query，图像Token只作为K/V。输出 Z 用于生成语言Prompt，不参与视觉编码器后续各层的计算。

3.5 动态语言Prompt

Directional Workspace通过映射函数 $g_\theta : \mathbb{R}^D \rightarrow \mathbb{R}^{d_l}$ 逐槽转换为语言侧残差：

$$\Delta P^d = g_\theta(Z). \quad (8)$$

参考零初始化适配器的做法[36]， g_θ 的输出层在训练开始时置零，因此初始动态残差为零。模型另维护10个静态可训练Anchor $A^t \in \mathbb{R}^{m \times d_l}$ ，最终动态Prompt为

$$P^d = A^t + \Delta P^d. \quad (9)$$

由于输出层从零开始训练，初始状态下 $P^d = A^t$ ；训练后，样本差异由 ΔP^d 表示。记Merger输出的视觉表示为 $M(I)$ ，原始文本Token为 $T(X)$ 。下一小节说明它们在LLM输入中的排列顺序。

当前密集配置包含20个静态语言Prompt和10个问题条件动态Prompt。推理时，动态分支执行问题池化、视觉Cross-Attention和Prompt映射，不针对测试样本进行反向传播。

3.6 Prompt放置与因果可见性

自回归LLM中的Token顺序会改变各类Prompt能够影响的后续表示。QDPT采用图3所示的输入顺序：静态领域Prompt位于视觉Token之前，问题条件的动态Prompt位于视觉Token之后、问题Token之前。对应的输入序列为

$$E_{\text{LLM}} = [P^t; M(I); P^d; T(X)]. \quad (10)$$




Fig. 3 QDPT在冻结因果LLM中的Prompt放置。静态Prompt位于视觉Token之前，用作领域先验；问题引导的证据Prompt位于视觉Token之后并紧邻问题。箭头表示由因果掩码决定的前向可见方向。

静态Prompt位于序列前部，后续视觉Token、动态Prompt和问题Token都能在LLM自注意力中访问它。动态Prompt由当前图像与问题共同生成，放在视觉Token之后，可以在LLM内部继续结合前面的静态Prompt和视觉表示；问题及答案Token则能访问动态Prompt。若将静态Prompt移到视觉Token之后，因果掩码会阻止它影响前面的视觉表示。本文在模型、训练协议和Prompt数量不变的条件下比较不同排列，结果见实验部分。

3.7 参数规模与适配路径

训练时只更新QDPT适配器，视觉编码器、Merger、词嵌入层和LLM均保持冻结。QDPT共有7,805,184个可训练参数，具体组成见表1。静态语言Prompt、动态Prompt Anchor和静态视觉Prompt合计95,232个参数，占适配器的1.22%；其余7,709,952个参数用于问题池化、视觉K/V投影、16头Cross-Attention和动态Prompt输出头。

Table 1 QDPT的可训练参数组成。

模块	配置	参数量
静态语言Prompt P^t	20×2560	51,200
动态Prompt Anchor A^t	10×2560	25,600
静态视觉Prompt P^v	18×1024	18,432
问题池化、跨模态检索与输出头	$D = 768$	7,709,952
合计		7,805,184

动态生成器的参数量主要由宽度 D 和输出头决定。实验部分比较默认输出头与秩256压缩输出头，考察输出映射容量对性能和参数量的影响。适配器文件变小也不意味着训练时间会等比例缩短，因为冻结骨干仍需完成前向计算并参与梯度回传。

对每个样本，问题表示从视觉K/V中聚合与当前问题相关的证据，形成动态表示 Z ；输出头 g_θ 再将 Z 映射为10个Prompt Token，并插入LLM输入序列。 Z 不返回视觉编码器。视觉编码阶段只引入18个由所有样本共享的静态Prompt，样本相关的动态表示则用于调整语言模型的输入上下文。

4 实验

本章在同一冻结骨干和评价脚本下比较QDPT、静态Prompt、实例条件Prompt与LoRA，并通过输入位置和输出头容量实验分析具体结构。

4.1 实验设置

4.1.1 数据集

视觉问答要求模型根据图像和自然语言问题生成答案[37]。PathVQA[6]是主要开发数据集。结构选择在官方Validation划分上完成，Test划分仅用于最终配置的评估。本文同时报告Overall、Yes/No和Free-form准确率，以区分封闭式判断与开放式生成。

SLAKE[7]用于检查同一结构在另一数据集上的表现。QDPT沿用在PathVQA上确定的Prompt长度、视觉层和适配宽度，不根据SLAKE结果重新搜索结构。除Overall外，实验还统计CLOSED与OPEN、KVQA与VQA，以及英文和中文问题。

自建电力电气数据集由本实验室采购的电力设备图像及目标检测标注整理而成。训练集包含20,015张图像，并借助Gemma 3 27B IT将检测标签、类别、目标数量和场景信息转换为36,700条多模态指令，任务包括设备与部件识别、缺陷与异常判断。固定测试集包含972张训练集之外的图像，每张图像对应一道经过人工核对的选择题。统一评价得到954条有效预测，另有18条样本因数据问题跳过。QDPT使用训练seed 47和数据划分seed 42。

4.1.2 比较方法

所有方法使用同一Qwen3-VL骨干[3]、图像预处理和答案评估脚本。Static LLM Prompt、Static Visual Prompt与Dual Static Prompt分别在语言侧、视觉侧或两侧加入样本共享的连续Prompt[14, 16]。CoCoOp-style根据图像均值特征生成语言Prompt，其条件化思路来自CoCoOp[20]，并适配到生成式MLLM。GRASP[27]采用本文按论文描述实现的版本，使用相同的三轮训练协议。Full-Attention LoRA-r8[10]在语言模型全部注意力层加入秩为8的低秩更新，作为权重空间适配参照。

4.1.3 训练与评价协议

QDPT冻结视觉编码器、Merger、词嵌入层和LLM，只更新第3节定义的适配器。主要实验训练三个Epoch，有效Batch Size为32。多随机种子实验使用44、45和46；单次对照默认使用seed 44。电气数据集使用训练seed 47和数据划分seed 42。实验在单张NVIDIA GeForce RTX 5090上完成，采用BF16精度，最大序列长度为2048。软件环境为PyTorch 2.8.0、torchvision 0.23.0和Transformers 5.0.0，其中PyTorch与torchvision均使用CUDA 12.8构建，GPU驱动支持CUDA 13.0。

主指标为答案归一化后的Exact Match准确率。三次运行以均值±样本标准差报告，单次运行直接报告准确率，各表同时列出种子数。训练时间采用相同的软硬件环境和计时口径。

Table 2 PathVQA Validation上的受控比较 (%)。三次运行报告均值±标准差，其他方法报告单次结果。GRASP为统一三轮协议下的独立实现。

方法	参数量	种子数	Overall	Yes/No	Free-form
Static Visual Prompt	0.020M	1	35.95	68.70	3.29
Dual Static Prompt	0.072M	1	54.63	88.38	20.96
Static LLM Prompt	0.051M	3	55.08 ± 0.22	88.95 ± 0.55	21.30 ± 0.91
CoCoOp-style	0.873M	3	56.31 ± 1.14	89.35 ± 0.59	23.37 ± 1.69
GRASP (independent impl.)	2.633M	1	39.75	75.36	4.24
QDPT	7.805M	3	59.15 ± 1.75	91.65 ± 1.03	26.75 ± 2.51
Full-Attention LoRA-r8	7.078M	3	59.26 ± 0.07	91.72 ± 0.41	26.90 ± 0.28

Table 3 PathVQA Test结果 (%)。

方法	种子数	Overall	Yes/No	Free-form
Frozen Base	1	34.7700	67.3400	2.1400
Static LLM Prompt	1	55.8268	90.3331	21.2690
QDPT	3	58.8827 ± 1.8141	91.3246 ± 1.1491	26.3926 ± 2.4909

4.2 PathVQA结果

4.2.1 Validation上的受控比较

表2汇总PathVQA Validation结果。最终QDPT的三随机种子平均Overall为59.1522，与LoRA-r8的59.2640相差0.1118个百分点，二者基本持平。QDPT高于Static LLM Prompt和CoCoOp-style，但其标准差也更大。单次运行中，Static Visual Prompt的Free-form准确率为3.2865；同时在视觉侧和语言侧加入静态Prompt后，Dual Static Prompt的Overall升至54.6253。按统一协议实现的GRASP取得39.7508，低于其他语言侧或双侧Prompt方法。

4.2.2 最终Test结果

结构确定后，最终QDPT在PathVQA Test上运行三个随机种子，结果见表3。其平均Overall为58.8827，较Static LLM Prompt高3.0559个百分点；Free-form准确率提高5.1236个百分点。

4.3 SLAKE跨数据集结果

表4给出SLAKE Test结果。QDPT的平均Overall为76.95，比Static LLM Prompt高2.55个百分点，在OPEN、VQA及中英文子集上也取得更高准确率。LoRA-r8达到81.82，比QDPT高4.87个百分点，并在各项拆分上保持优势。SLAKE包含知识型问题和双语问题，LoRA在这些任务上的适配更充分。

Table 4 SLAKE Test结果 (%)。三次运行报告均值±标准差。

方法	种子数	Overall	CLOSED	OPEN
Static LLM Prompt	1	74.40	80.62	70.27
QDPT	3	76.95 ± 0.44	84.01 ± 1.32	72.26 ± 1.14
Full-Attention LoRA-r8	3	81.82 ± 0.22	87.00 ± 0.39	78.38 ± 0.62

方法	KVQA	VQA	EN	ZH
Static LLM Prompt	62.55	76.14	75.40	73.38
QDPT	62.17 ± 0.00	79.11 ± 0.51	77.51 ± 1.44	76.38 ± 0.64
Full-Attention LoRA-r8	70.41 ± 1.72	83.49 ± 0.08	82.85 ± 0.41	80.77 ± 0.05

Table 5 自建电力电气数据集固定留出集结果 (%)。每种方法均为单次运行，共954条有效预测。

方法	可训练参数	Overall
Static LLM Prompt	51,200	70.06
CoCoOp-style	873,120	70.88
Full-Attention LoRA-r8	7,077,888	70.69
QDPT	7,805,184	71.91

Table 6 PathVQA Validation上的Prompt放置位置消融 (seed 44, %)。三种配置均含7,805,184个可训练参数。

输入顺序	Overall	Yes/No	Free-form	Δ Overall
$[P^t; M(I); P^d; T(X)]$ (QDPT)	60.7765	92.7360	28.9100	0.0000
$[M(I); P^t; P^d; T(X)]$	59.2587	91.6160	26.9943	-1.5178
$[P^d; M(I); P^t; T(X)]$	58.1243	91.4880	24.8564	-2.6522

4.4 电力电气数据集结果

固定留出集上的结果列于表5。最终QDPT得到71.91的总体准确率，分别比Static LLM Prompt、CoCoOp-style和LoRA-r8高1.85、1.03和1.22个百分点。QDPT在电力设备图像上保持了问题条件Prompt的适配能力，并取得四种方法中的最高准确率。

4.5 Prompt放置位置消融

因果LLM只能访问当前位置之前的Token，三类Prompt的排列会改变信息传播路径。表6固定模型、参数量、初始化和训练协议，只调整输入顺序。QDPT采用的顺序取得60.7765的Overall；将两类Prompt都放在视觉Token之后时，Overall下降1.5178个百分点；交换静态与动态Prompt的位置后，下降2.6522个百分点。

Table 7 PathVQA Validation上的动态Prompt输出头容量对照 (seed 44, %)。

配置	可训练参数	Overall	Yes/No	Free-form
QDPT (默认输出头)	7,805,184	60.7765	92.7360	28.9100
QDPT (秩256输出头)	6,100,736	57.4213	90.7840	24.1544

Table 8 QDPT与LoRA-r8的实测效率。PathVQA训练时间为seed 45/46均值，SLAKE为三个随机种子均值。

数据集	方法	训练时间 (s)	TTFT (s)	TPOT (s/token)
PathVQA	QDPT	6629.11	—	—
PathVQA	Full-Attention LoRA-r8	14848.75	—	—
SLAKE	QDPT	4739.96	0.067779	0.020091
SLAKE	Full-Attention LoRA-r8	7039.16	0.071839	0.024217

Table 9 PathVQA Validation Overall的随机种子稳定性 (%)。

方法	Seed 44	Seed 45	Seed 46	Mean $\pm$ SD	Range
Full-Attention LoRA-r8	59.3386	59.2427	59.2107	59.2640 $\pm$ 0.0666	0.1279
Static LLM Prompt	54.8650	55.0567	55.3124	55.0780 $\pm$ 0.2244	0.4474
CoCoOp-style	57.4053	56.3988	55.1366	56.3136 $\pm$ 1.1367	2.2687
QDPT	60.7765	57.2935	59.3865	59.1522 $\pm$ 1.7528	3.4830

4.6 输出头容量与训练效率

输出头压缩实验保留 $D = 768$ 的Workspace，并将动态Prompt输出头改为秩256的低秩映射。表7显示，该改动减少21.84%的可训练参数，同时使Overall下降3.3552个百分点，Free-form下降4.7556个百分点。动态Prompt输出映射需要足够的容量，秩256压缩带来的精度损失超过了参数收益。

训练耗时见表8。PathVQA的seed 45和46中，QDPT平均用时6629.11秒，LoRA-r8为14848.75秒，前者约快2.24倍。SLAKE三随机种子的平均训练时间分别为4739.96秒和7039.16秒，约相差1.49倍。SLAKE推理中，QDPT的TTFT和TPOT也略低。冻结骨干的前向与反向计算占据了主要开销，因此端到端耗时不会随可训练参数量同比变化。

4.7 随机种子稳定性

表9列出PathVQA Validation上的三随机种子结果。LoRA-r8的标准差为0.0666，Static LLM Prompt为0.2244；两个实例条件Prompt方法的波动更大，CoCoOp-style和QDPT分别为1.1367与1.7528。QDPT三次运行的范围达到3.4830个百分点，训练稳定性低于Static LLM Prompt和LoRA-r8。

4.8 结果讨论

三个数据集呈现出不同的适配特征。QDPT在PathVQA上与LoRA-r8接近,在SLAKE上低4.87个百分点,在电力电气留出集上高1.22个百分点。它在两个公开数据集上的训练时间均短于LoRA-r8,代价是PathVQA上更大的随机种子波动。结果表明,问题引导的动态Prompt更适合围绕视觉证据组织回答;当任务同时要求较强的知识与语言适配时,直接更新注意力权重的LoRA表现更好。

References

- [1] Alayrac, J.-B., Donahue, J., Luc, P., Miech, A., Barr, I., Hasson, Y., Lenc, K., Mensch, A., Millican, K., Reynolds, M., Ring, R., Rutherford, E., Cabi, S., Han, T., Gong, Z., Samangooei, S., Monteiro, M., Menick, J., Borgeaud, S., Brock, A., Nematzadeh, A., Sharifzadeh, S., Binkowski, M., Barreira, R., Vinyals, O., Zisserman, A., Simonyan, K.: Flamingo: A visual language model for few-shot learning. In: Advances in Neural Information Processing Systems (2022). <https://arxiv.org/abs/2204.14198>
- [2] Li, J., Li, D., Savarese, S., Hoi, S.C.H.: BLIP-2: Bootstrapping language-image pre-training with frozen image encoders and large language models. In: Proceedings of the 40th International Conference on Machine Learning, pp. 19730–19742 (2023). PMLR
- [3] Bai, S., Cai, Y., Chen, R.-Z., Chen, K., Chen, X.-H., Cheng, Z., Deng, L.-H., Ding, W., Fang, R., Gao, C., Ge, C., Ge, W., Guo, Z., Huang, Q., Huang, F., Hui, B., Jiang, S., Li, Z., Li, M.-S., Li, M., Li, K., Lin, Z., Lin, J., Liu, X.-J., Liu, J., Liu, C., Liu, Y., Liu, D., Liu, S., Lu, D., Luo, R., Lv, C., Men, R., Meng, L.Y., Meng, L., Ren, X.-Y., Song, S., Sun, Y.-C., Tang, J., Tu, J., Wan, J., Wang, P., Wang, P., Wang, Q., Wang, Y., Xie, T., Xu, Y., Xu, H., Xu, J., Yang, Z., Yang, M., Yang, J., Yang, A., Yu, B., Zhang, F., Zhang, H., Zhang, X., Zheng, B., Zhong, H., Zhou, J., Zhou, F., Zhu, Y., Zhu, K.: Qwen3-VL technical report. arXiv preprint arXiv:2511.21631 (2025)
- [4] Liu, H., Li, C., Wu, Q., Lee, Y.J.: Visual instruction tuning. arXiv preprint arXiv:2304.08485 (2023)
- [5] Zhu, D., Chen, J., Shen, X., Li, X., Elhoseiny, M.: MiniGPT-4: Enhancing vision-language understanding with advanced large language models. arXiv preprint arXiv:2304.10592 (2023)
- [6] He, X., Zhang, Y., Mou, L., Xing, E.P., Xie, P.: PathVQA: 30000+ questions for medical visual question answering. arXiv preprint arXiv:2003.10286 (2020)
- [7] Liu, B., Zhan, L.-M., Xu, L., Ma, L., Yang, Y., Wu, X.-M.: SLAKE: A semantically-labeled knowledge-enhanced dataset for medical visual question answering. In: 2021 IEEE 18th International Symposium on Biomedical Imaging (ISBI), pp. 1650–1654 (2021).

<https://api.semanticscholar.org/CorpusID:231951663>

- [8] Wang, J., Li, M., Luo, H., Zhu, J., Yang, A., Rong, M., Wang, X.: Power-LLaVA: Large language and vision assistant for power transmission line inspection. In: 2024 IEEE International Conference on Image Processing (ICIP), pp. 963–969 (2024). <https://arxiv.org/abs/2407.19178>
- [9] Hounsby, N., Giurigu, A., Jastrzebski, S., Morrone, B., Laroussilhe, Q., Gesmundo, A., Attariyan, M., Gelly, S.: Parameter-efficient transfer learning for NLP. In: Proceedings of the 36th International Conference on Machine Learning, pp. 2790–2799 (2019). PMLR
- [10] Hu, E.J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., Chen, W.: LoRA: Low-rank adaptation of large language models. In: International Conference on Learning Representations (ICLR) (2022). <https://arxiv.org/abs/2106.09685>
- [11] Liu, H., Tam, D., Muqeeth, M., Mohta, J., Huang, T., Bansal, M., Raffel, C.: Few-shot parameter-efficient fine-tuning is better and cheaper than in-context learning. arXiv preprint arXiv:2205.05638 (2022)
- [12] Zhang, Q., Chen, M., Bukharin, A., Karampatziakis, N., He, P., Cheng, Y., Chen, W., Zhao, T.: AdaLoRA: Adaptive budget allocation for parameter-efficient fine-tuning. (2023). <https://api.semanticscholar.org/CorpusID:266435293>
- [13] Li, X.L., Liang, P.: Prefix-tuning: Optimizing continuous prompts for generation. In: Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing, pp. 4582–4597 (2021)
- [14] Lester, B., Al-Rfou, R., Constant, N.: The power of scale for parameter-efficient prompt tuning. In: Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing, pp. 3045–3059 (2021)
- [15] Liu, X., Ji, K., Fu, Y., Du, Z., Yang, Z., Tang, J.: P-Tuning v2: Prompt tuning can be comparable to fine-tuning universally across scales and tasks. arXiv preprint arXiv:2110.07602 (2021)
- [16] Jia, M., Tang, L., Chen, B.-C., Cardie, C., Belongie, S., Hariharan, B., Lim, S.-N.: Visual prompt tuning. In: European Conference on Computer Vision, pp. 709–727 (2022). Springer
- [17] Dai, W., Li, J., Li, D., Tiong, A., Zhao, J., Wang, W., Li, B., Fung, P.N., Hoi, S.C.H.: InstructBLIP: Towards general-purpose vision-language models with instruction tuning. *Advances in Neural Information Processing Systems* **36**, 49250–49267 (2023)

- [18] Radford, A., Kim, J.W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J., Krueger, G., Sutskever, I.: Learning transferable visual models from natural language supervision. arXiv preprint arXiv:2103.00020 (2021)
- [19] Zhou, K., Yang, J., Loy, C.C., Liu, Z.: Learning to prompt for vision-language models. *International Journal of Computer Vision* **130**, 2337–2348 (2021)
- [20] Zhou, K., Yang, J., Loy, C.C., Liu, Z.: Conditional prompt learning for vision-language models. In: 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 16795–16804 (2022). <https://api.semanticscholar.org/CorpusID:247363011>
- [21] Khattak, M.U., Rasheed, H.A., Maaz, M., Khan, S.H., Khan, F.S.: MaPLe: Multi-modal prompt learning. 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 19113–19122 (2022)
- [22] Hu, T., Zhou, D.-W.: Dynamic cross-modal prompt generation for multimodal continual instruction tuning. arXiv preprint arXiv:2605.10765 (2026)
- [23] Jaegle, A., Gimeno, F., Brock, A., Zisserman, A., Vinyals, O., Carreira, J.: Perceiver: General perception with iterative attention. arXiv preprint arXiv:2103.03206 (2021)
- [24] Ryoo, M.S., Piergiovanni, A.J., Arnab, A., Dehghani, M., Angelova, A.: Token-Learner: What can 8 learned tokens do for images and videos? arXiv preprint arXiv:2106.11297 (2021)
- [25] Zhou, X., He, J., Ke, Y., Zhu, G., Gutiérrez-Basulto, V., Pan, J.Z.: An empirical study on parameter-efficient fine-tuning for multimodal large language models. In: Findings of the Association for Computational Linguistics: ACL 2024, pp. 10057–10084 (2024)
- [26] Sung, Y.-L., Cho, J., Bansal, M.: VL-Adapter: Parameter-efficient transfer learning for vision-and-language tasks. arXiv preprint arXiv:2112.06825 (2021)
- [27] Sun, Q., Zhang, C., Zhang, J., Wang, X., Xie, J., Zheng, P., Wang, H., Lee, S., Tai, C.-I.A., Yang, Y., Shen, H.T.: GRASP: Guided region-aware sparse prompting for adapting MLLMs to remote sensing. arXiv preprint arXiv:2601.17089 (2026)
- [28] Qian, J., Shen, Y., Chen, Z., Zhou, J., Wang, P.: CoTBox-TTT: Grounding medical VQA with visual chain-of-thought boxes during test-time training. arXiv preprint arXiv:2511.12446 (2025)
- [29] Rocha, P.D., Lopes, F.J.P., Cruz, L.A.d.S.: Advances in electrical grid assets inspection: Exploring multimodal large language models. In: 2025 25th International Conference on Digital Signal Processing (DSP), pp. 1–5 (2025).

<https://api.semanticscholar.org/CorpusID:280164358>

- [30] Hao, J., Tao, Y.: Power grid inspection based on multimodal foundation models. *EAI Endorsed Transactions on Energy Web* **12** (2025)
- [31] Lin, Z., Xu, K., Aung, A.P.P., Qiu, W., Zee, B., Chin, J.M., Jayavelu, S.: Defect-GPT: Towards multi-class defect detection with limited electrical samples. In: *Proceedings of the British Machine Vision Conference (BMVC)* (2025)
- [32] Wu, J., Chen, Y., Min, Q., Chen, M., Zhao, J., Ye, M.: Domain-adaptive multimodal large language models for photovoltaic fault diagnosis via dynamic LoRA routing. *Processes* **14**(4), 653 (2026)
- [33] Anderson, P., He, X., Buehler, C., Teney, D., Johnson, M., Gould, S., Zhang, L.: Bottom-up and top-down attention for image captioning and visual question answering. *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 6077–6086 (2017)
- [34] Kim, J.-H., Jun, J., Zhang, B.-T.: Bilinear attention networks. In: *Advances in Neural Information Processing Systems* (2018). <https://api.semanticscholar.org/CorpusID:29150617>
- [35] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, L., Polosukhin, I.: Attention is all you need. In: *Advances in Neural Information Processing Systems*, vol. 30 (2017). <https://api.semanticscholar.org/CorpusID:13756489>
- [36] Zhang, R., Han, J., Zhou, A., Hu, X., Yan, S., Lu, P., Li, H., Gao, P., Qiao, Y.J.: LLaMA-Adapter: Efficient fine-tuning of language models with zero-init attention. *arXiv preprint arXiv:2303.16199* (2023)
- [37] Agrawal, A., Lu, J., Antol, S., Mitchell, M., Zitnick, C.L., Parikh, D., Batra, D.: VQA: Visual question answering. *International Journal of Computer Vision* **123**, 4–31 (2015)